Univerzita Komenského v Bratislave
Fakulta matematiky, fyziky a informatiky

Generovanie 3D scén na základe textových promptov

Ročníkový projekt a úvod do bakalárskej práce

2026
Šimon Hajkovský

Univerzita Komenského v Bratislave
Fakulta matematiky, fyziky a informatiky

Generovanie 3D scén na základe textových promptov

Ročníkový projekt a úvod do bakalárskej práce

Študijný program:	Aplikovaná informatika
Študijný odbor:	Aplikovaná informatika
Školiace pracovisko:	Katedra aplikovanej informatiky
Školiteľ:	doc. RNDr. Martin Madaras, PhD.

Bratislava, 2026
Šimon Hajkovský

Abstrakt

Práca sa zaoberá návrhom spracovateľského reťazca, ktorý z bežných fotografií alebo videa reálnej scény vytvára jej fotorealistickú a zároveň editovateľnú trojrozmernú reprezentáciu. Cieľom je umožniť úpravu scény pomocou textových a obrázkových promptov, napríklad výmenu alebo premiestnenie konkrétneho objektu. Reťazec je rozdelený do šiestich na seba nadväzujúcich fáz: odhad geometrie a pozícií kamier, dvojrozmerná segmentácia objektov, prenos sémantiky do priestoru, budovanie grafovej reprezentácie scény, samotná modifikácia a záverečné fotorealistické zobrazovanie. Pre každú fázu práca popisuje jej vstup, výstup a postup spracovania, porovnáva zvažovaných kandidátov a zdôvodňuje finálny výber, pričom pre každú fázu volí najzrelšiu a prakticky najlepšie použiteľnú metódu. Výsledkom je odporúčaný stack metód, posúdenie zrelosti jednotlivých komponentov a návrh poradia ich integrácie. Práca zároveň identifikuje fázu modifikácie scény ako úzke hrdlo celého reťazca a hlavný priestor pre ďalší výskum.

Kľúčové slová: generovanie 3D scén, Gaussian Splatting, graf scény (scene graph), textové prompty, počítačové videnie

Abstract

This work proposes a processing pipeline that turns ordinary photographs or video of a real scene into a photorealistic and, at the same time, editable three-dimensional representation. The goal is to allow the scene to be modified through text and image prompts, for example by replacing or relocating a specific object. The pipeline is divided into six consecutive stages: estimation of geometry and camera poses, two-dimensional object segmentation, lifting semantics into 3D, building a graph representation of the scene, the modification itself, and final photorealistic rendering. For each stage the work describes its input, output and processing procedure, compares the candidate methods and justifies the final choice, selecting for each stage the most mature and practically usable option. The result is a recommended stack of methods, an assessment of the maturity of the individual components and a proposed order of their integration. The work also identifies the scene-modification stage as the bottleneck of the whole pipeline and the main avenue for further research.

Keywords: 3D scene generation, Gaussian Splatting, scene graph, text prompts, computer vision

Obsah

Úvod **1**

1 Súčasný stav **2**
1.1 Rekonštrukcia geometrie a kamier 2
1.2 Fotorealistické zobrazenie 2
1.3 Porozumenie scéne 2
1.4 Úprava 3D scén promptmi 3

2 Návrh reťazca **4**
2.1 Cieľ a požiadavky 4
2.2 Architektúra a tok dát 4

3 Jednotlivé fázy a výber metód **6**
3.1 Fáza 01: Structure-from-Motion 6
3.2 Fáza 02: 2D segmentácia objektov 6
3.3 Fáza 03: 2D $\rightarrow$ 3D lifting 7
3.4 Fáza 04: Scene graph 8
3.5 Fáza 05: Úprava cez prompt 9
3.6 Fáza 06: Gaussian Splatting a render 9

4 Zhrnutie a plán **11**
4.1 Odporúčaný stack 11
4.2 Pripravenosť a poradie skladania 11
4.3 Zhodnotenie 12

Záver **13**

Literatúra **14**

Zoznam obrázkov

2.1 Tok dát v reťazci 5

3.1 Príklad rekonštrukcie Structure-from-Motion 7
3.2 Príklad výstupu Grounded-SAM 7
3.3 Pipeline metódy ConceptGraphs 8
3.4 Príklad úpravy scény pomocou GaussianEditor 9
3.5 Scéna v reprezentácii 3D Gaussian Splatting 10

Zoznam tabuliek

2.1 Prehľad fáz reťazca 5

4.1 Odporúčaný stack metód 11

Úvod

Vytvoriť 3D model scény z obyčajných fotiek je dnes oveľa jednoduchšie ako pred pár rokmi. Veľký posun priniesla metóda 3D Gaussian Splatting [4], ktorá vie scénu zobraziť fotorealisticky a v reálnom čase. Taktiež sa zlepšili aj modely na rozpoznávanie a segmentáciu objektov [6, 5], ktoré dokážu nájsť objekty na obrázku aj bez vopred daného zoznamu tried. Keď tieto dve veci spojíme, dostaneme zaujímavú možnosť: scénu nielen verne zrekonštruovať, ale jej aj porozumieť a následne ju upravovať obyčajným textom.

Cieľom tejto práce je navrhnúť postup (*pipeline*), ktorý z fotiek alebo videa reálnej scény vytvorí jej upraviteľnú 3D verziu. Na vstupe je sada snímok scény (napríklad izby alebo exteriéru), na výstupe je fotorealistická 3D reprezentácia plus graf scény (*scene graph*), ktorý sa dá meniť textovými alebo obrázkovými promptmi — napríklad príkazom „zameň hnedý gauč za modrý stôl“. Takýto výstup spája pekné zobrazenie s možnosťou meniť jednotlivé objekty, čo sa hodí napríklad pri vizualizácii interiérov alebo vo virtuálnej a rozšírenej realite.

Aby to celé fungovalo, treba poskladať viacero úloh počítačového videnia: odhad pozícií kamier, segmentáciu objektov, prenos významu z 2D do 3D, zostavenie grafu scény, samotnú úpravu a záverečné zobrazenie. Každá z nich je sama o sebe celá oblasť výskumu. Táto práca preto nevymýšľa novú metódu, ale skladá celý reťazec dokopy a pre každú jeho fázu vyberá a zdôvodňuje vhodnú existujúcu metódu. Pri výbere idem po praktickej stránke: pre každú fázu porovnám dostupných kandidátov a vyberiem ten najzrelší — teda dobre zdokumentovaný, produkčne overený a jednoducho použiteľný. Vďaka tomu sa dá reťazec reálne poskladať z existujúcich open-source nástrojov.

Práca je členená takto. V kapitole 1 stručne zhrniem, ako na tom jednotlivé úlohy dnes sú. V kapitole 2 ukážem celý reťazec, jeho šesť fáz a to, ako medzi nimi tečú dáta. Kapitola 3 je jadrom práce: pri každej fáze popíšem jej vstup, výstup a postup, porovnám možnosti a vyberiem jednu metódu. V kapitole 4 potom zhrniem odporúčaný stack, zhodnotím, ako sú jednotlivé časti pripravené na použitie, a navrhnem poradie ich skladania.

Kapitola 1

Súčasný stav

Navrhovaný reťazec spája niekoľko oblastí počítačového videnia a grafiky. V tejto kapitole o každej z nich poviem to najnutnejšie, aby bolo jasné, na čom ďalšie kapitoly stavajú.

1.1 Rekonštrukcia geometrie a kamier

Prvý krok je z neusporiadaných fotiek zistiť, kde stáli kamery a kde sú body scény. Túto úlohu rieši *Structure-from-Motion* (SfM). Dlhoročným štandardom je systém COLMAP [8], ktorý pridáva snímky postupne a priebežne dolaďuje rekonštrukciu (*bundle adjustment*). Je presný, spoľahlivý, dobre zdokumentovaný a používa sa skoro vo všetkých 3DGS aj NeRF reťazcoch. Novšie tzv. metódy založené na neurónových sieťach (napríklad MASt3R alebo VGGSfM) si poradia aj s ťažšími scénami (málo textúry, málo snímok), no sú novšie a menej overené.

1.2 Fotorealistické zobrazenie

Aby sme scénu vedeli pekne zobraziť z ľubovoľného uhla, používali sa donedávna neurónové radiačné polia (NeRF), ktoré sú však pomalé. 3D Gaussian Splatting [4] miesto toho scénu opíše ako množinu miliónov malých 3D gaussiánov (poloha, tvar, priehľadnosť a farba). Zobrazuje sa v reálnom čase (bežne cez 100 FPS) a dá sa trénovať gradientom, a preto na ňom dnes stavia väčšina editorov 3D scén.

1.3 Porozumenie scéne

Aby sme scénu vedeli meniť po objektoch, treba jej priradiť význam. V 2D obraze to zvládajú veľké predtrénované modely: SAM 2 [6] robí presné masky objektov a vie ich sledovať naprieč snímkami, Grounding DINO [5] zase nájde objekt podľa textu. Ich

spojenie, Grounded-SAM [7], dáva masky aj s kategóriou a CLIP príznakom v jednom kroku.

O úroveň vyššie je graf scény: uzly sú objekty s vlastnosťami, hrany sú vzťahy medzi nimi. ConceptGraphs [2] taký graf postavia priamo z videa, ku každému objektu pridajú CLIP príznak aj textový popis a vzťahy medzi objektmi odvodia cez jazykový model. Existujú aj hierarchické grafy ako HOV-SG [9] (budova $\rightarrow$ izba $\rightarrow$ objekt), tie sú ale pre menšiu scénu zbytočne zložité.

1.4 Úprava 3D scén promptmi

Poslednou úlohou je samotná úprava. Pri Gaussian Splattingu ju rieši GaussianEditor [1] — editor 3DGS scén riadený textom, ktorý zvláda zmenu farby, štýlu aj výmenu objektu a je z dostupných nástrojov najzrelší. Pre NeRF ukázala podobnú myšlienku metóda Instruct-NeRF2NeRF [3] (úprava scény inštrukciami cez difúzne modely), tá sa však dá využiť len ako inšpirácia. Práve táto fáza je z celého reťazca najmenej ustálená a vrátim sa k nej v kapitole 4.

Kapitola 2

Návrh reťazca

2.1 Cieľ a požiadavky

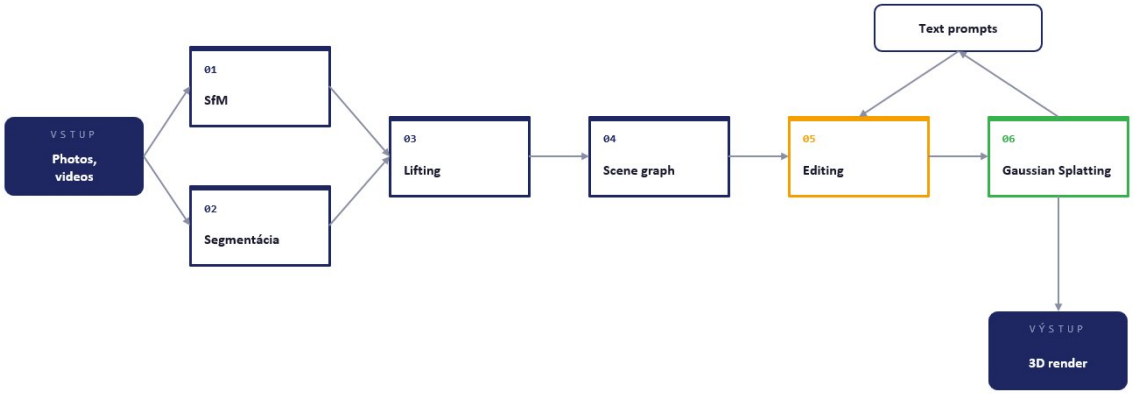
Reťazec má z obyčajných fotiek scény spraviť jej upraviteľnú 3D verziu. Na vstup kladiem čo najmenšie nároky: stačí sada RGB snímok alebo video scény z rôznych uhlov, bez hĺbkového senzora a bez kalibrácie kamery. Na výstupe sú dve prepojené veci — fotorealistická scéna vo formáte 3D Gaussian Splatting na zobrazovanie a graf scény na dotazy a úpravy. Úprava sa má dať spustiť textovým alebo obrázkovým promptom a musí sa prejaviť v oboch reprezentáciách naraz.

Z toho vyplýva pár rozhodnutí. Ako hlavnú reprezentáciu volím 3D Gaussian Splatting, lebo nad ním je postavená väčšina dostupných editorov. Reťazec navrhujem ako *offline* — najprv všetko nafotím a až potom spracujem, čo mi dovolí v každej fáze uprednostniť kvalitu pred rýchlosťou. A namiesto jedného veľkého riešenia robím *modulárny* návrh, kde je každá fáza samostatne vymeniteľná; vďaka tomu sa dá ktorákoľvek metóda nahradiť inou bez zásahu do zvyšku. To je v tejto oblasti obzvlášť dôležité, lebo technológie sa vyvíjajú veľmi rýchlo — skoro v každej fáze pravidelne pribúdajú nové a lepšie metódy. Vďaka modulárnosti ich stačí vymeniť za starý modul a zvyšok reťazca ostáva nedotknutý.

2.2 Architektúra a tok dát

Reťazec som rozdelil do šiestich fáz, kde výstup jednej fázy je vstupom ďalšej. Celý tok dát od fotiek po hotový render ukazuje obrázok 2.1, stručný prehľad fáz je v tabuľke 2.1.

Prvé tri fázy postupne budujú reprezentáciu scény: SfM (fáza 01) zistí geometriu a kamery, 2D segmentácia (fáza 02) priradí snímkam význam a prenos do 3D (fáza 03) oba zdroje spojí do sémantického pointcloudu, kde má každý bod priradený objekt. Fáza 04 z neho postaví graf scény, ktorý je mostom medzi textom a geometriou: prompt sa



Obr. 2.1: Tok dát od vstupných fotiek po editovateľný 3D render. Text prompty vstupujú do fázy úpravy (05).

Fáza	**Úloha**	**Hlavný výstup**
01	Structure-from-Motion	riedky pointcloud + pózy kamier
02	2D segmentácia	masky inštancií + CLIP embeddings
03	2D $\rightarrow$ 3D lifting	sémantický pointcloud (s ID)
04	Scene graph	objekty + vzťahy (uzly + hrany)
05	Úprava promptom	upravená scéna + aktualizovaný graf
06	Gaussian Splatting	real-time render

Tabuľka 2.1: Prehľad šiestich fáz reťazca a ich hlavných výstupov.

najprv namapuje na uzol grafu a až potom na konkrétne gaussiány. Fáza 05 spraví samotnú úpravu a fáza 06 sa stará o výsledné zobrazenie.

Dôležité je, že fázy 05 a 06 zdieľajú tú istú reprezentáciu (3D Gaussian Splatting), takže úprava prebieha priamo nad tým, čo aj vidíme. Naopak, fázy 03 a 04 si držia *symbolickú* vrstvu (ID objektov a graf), ktorá úpravu navádza. Toto prepojenie symbolickej a geometrickej vrstvy je podľa mňa kľúčové: bez grafu by prompt nemal na čo ukazovať a bez zdieľanej geometrie by sa úprava neprejavila v zobrazení.

Kapitola 3

Jednotlivé fázy a výber metód

V tejto kapitole prejdem každú zo šiestich fáz zvlášť. Pri každej napíšem jej vstup a výstup, ako funguje, akých kandidátov som zvažoval a ktorého som nakoniec vybral. Vyberám vždy tú metódu, ktorá je najzrelšia a prakticky najlepšie použiteľná — teda dobre zdokumentovaná, overená a ľahko prispôsobiteľná.

3.1 Fáza 01: Structure-from-Motion

Vstup: sada RGB snímok alebo video scény z rôznych uhlov. **Výstup:** pozície kamier (R, t), riedky 3D pointcloud a 2D–3D korešpondencie.

Postup je takýto: v každom obrázku sa nájdu význačné body (SIFT alebo SuperPoint), spárujú sa medzi dvojicami obrázkov, z toho sa cez epipolárnu geometriu a robustný odhad (RANSAC, resp. MAGSAC++) odhadnú vzájomné polohy kamier, body sa triangulujú do 3D a nakoniec sa všetko spolu doladí (Bundle Adjustment).

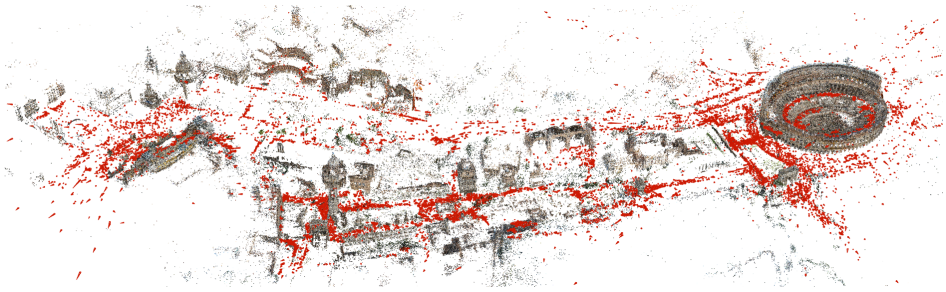
Vyberám **COLMAP** [8]. Je to štandard — robustný, dobre zdokumentovaný a široko používaný v 3DGS aj NeRF reťazcoch, takže jeho výstup priamo sedí s ďalšími fázami (hlavne s fázou 06). Ako kandidátov som zvažoval aj metódy založené na neurónových sieťach MASt3R a VGGSfM, ktoré sú lepšie na ťažké scény (málo textúry, málo obrázkov), no sú novšie a menej zrelé, preto ich nechávam len ako možnú náhradu do budúcna.

Príklad takejto rekonštrukcie ukazuje obrázok 3.1.

3.2 Fáza 02: 2D segmentácia objektov

Vstup: tie isté RGB obrázky ako pri SfM. **Výstup:** pre každý obrázok masky inštancií + CLIP embedding a textový label pre každú masku.

Najprv sa objekty nájdu (Grounding DINO + SAM 2), pre každý sa spravia presné masky (SAM 2), ku každej maske sa spočíta CLIP vektor a priradí textový label z

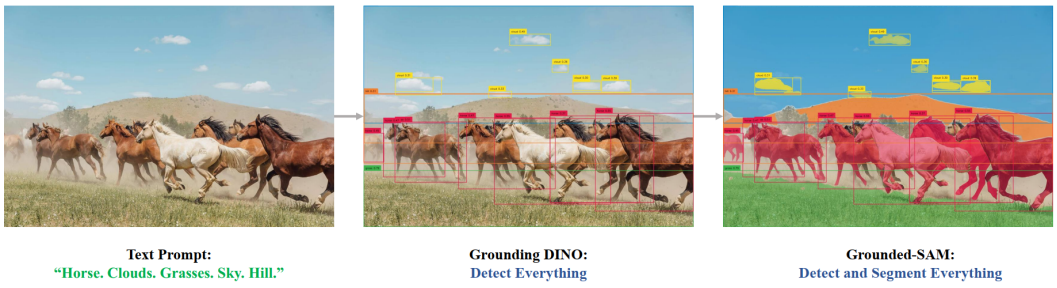


Obr. 3.1: Príklad rekonštrukcie metódou Structure-from-Motion: riedke mračno bodov mesta Rím (21 000 fotografií) a odhadnuté pózy kamier. Zdroj: dokumentácia COLMAP [8], `https://colmap.github.io/` [cit. 7. 6. 2026].

otvoreného slovníka.

Vyberám **Grounded-SAM 2** [7, 6, 5]. Je to open-vocabulary riešenie, ktoré dáva masky aj CLIP embeddingy v jednom reťazci, je stabilné v produkcii a masky majú dobrú kvalitu. Z kandidátov som zvažoval ODISE a OpenSeeD (open-vocab panoptická segmentácia, podobné výsledky, ale náročnejšie na nastavenie) a YOLO-World + SAM (rýchlejšie, no slabšie pri menej častých objektoch).

Postup spojenia detekcie a segmentácie ilustruje obrázok 3.2.



Obr. 3.2: Príklad výstupu reťazca Grounded-SAM: objekty detegované podľa textového zadania (Grounding DINO) a ich presné segmentačné masky (SAM). Zdroj: repozitár Grounded-SAM [7], `https://github.com/IDEA-Research/Grounded-Segment-Anything` [cit. 7. 6. 2026].

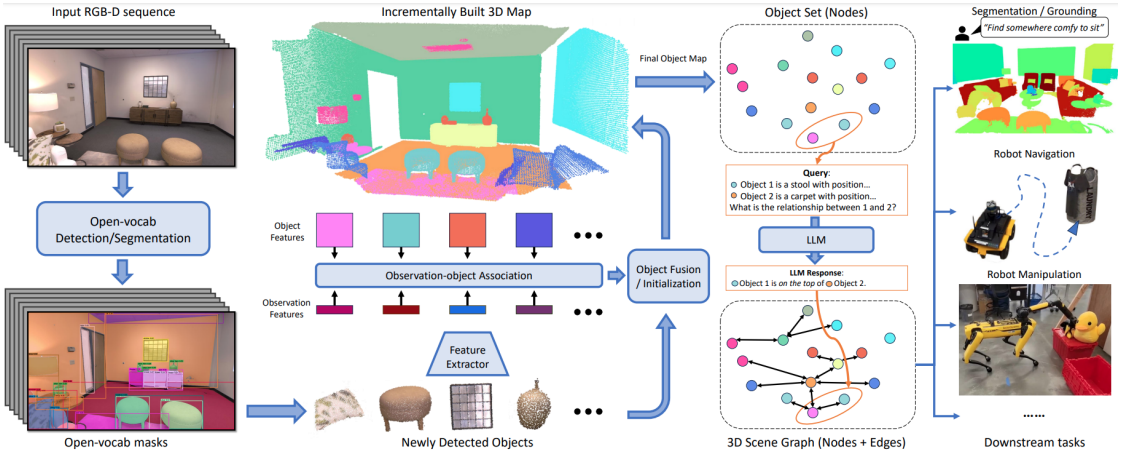
3.3 Fáza 03: 2D → 3D lifting

Vstup: 3D pointcloud a kamery z fázy 01, masky a embeddingy z fázy 02. **Výstup:** 3D pointcloud, kde má každý bod súradnice (x, y, z), CLIP embedding a instance ID.

Každý 3D bod sa premietne do obrázkov, v ktorých leží, pozbierajú sa prislúchajúce masky a CLIP embeddingy, inštancie sa spárujú naprieč pohľadmi (multi-view association), embeddingy sa zagregujú (s potlačením outlierov) a bodu sa priradí instance ID a finálny embedding.

Vyberám **ConceptGraphs** [2]. Je to kanonická referencia pre túto úlohu — modulárny, dobre zdokumentovaný open-source reťazec, ktorý sa dá ľahko prispôsobiť. Navyše pokrýva aj nasledujúcu fázu (graf scény), takže fázy 03 a 04 zvládne jeden systém a odpadá lepenie medzi nimi. Z kandidátov som zvažoval OpenMask3D (3D instance segmentácia cez SAM + CLIP, potrebuje však hustý pointcloud z MVS a je pomalšia) a OV-SAM3D (training-free, ale menej dokumentovaná).

Príklad takéhoto sémantického mračna bodov ukazuje obrázok 3.3.



Obr. 3.3: Pipeline metódy ConceptGraphs: z RGB(-D) snímok sa segmentujú objekty, spočítajú sa CLIP príznaky, tie sa spoja do 3D objektov (sémantické mračno bodov s inštanciami) a z nich sa vybuduje graf scény. Pokrýva teda fázy 03 aj 04. Zdroj: projektová stránka ConceptGraphs [2], `https://concept-graphs.github.io/` [cit. 7. 6. 2026].

3.4 Fáza 04: Scene graph

Vstup: sémantický pointcloud s inštanciami z fázy 03. **Výstup:** graf, kde uzly sú objekty {bbox, label, embedding} a hrany sú relácie (*on*, *inside*, *near*, *supports* ...).

Pre každú inštanciu sa spočíta 3D AABB a reprezentatívny embedding, vygeneruje sa caption objektu, geometrické relácie sa odvodia analyticky z bbox-ov a sémantické relácie nad captions a labelmi (cez LLM). Graf sa uloží v štruktúre JSON alebo NetworkX, pripravenej na úpravy.

Aj tu vyberám **ConceptGraphs** [2] — ten istý systém ako vo fáze 03. Pokrýva totiž obe fázy naraz, takže sa minimalizuje integrácia, ID objektov ostávajú konzistentné a captions aj relácie rieši cez LLM. Ako alternatívu som zvažoval hierarchický HOV-SG [9] (budova → izba → objekt, až o 75 % menšia pamäť), ten je však pre malú scénu overkill.

3.5 Fáza 05: Úprava cez prompt

Vstup: graf scény, 3D scéna (gaussiány) a textový alebo obrázkový prompt. **Výstup:** upravený graf scény a upravená 3D reprezentácia.

Prompt sa najprv rozparzuje na štruktúrovaný plán {target, op, params} (cez LLM), cieľový objekt sa nájde v grafe (CLIP podobnosť nad uzlami), operácia sa nasmeruje na vhodný mechanizmus (color/style → difúzny model, position → transformácia, replace → 3D generovanie) a úprava sa spraví nad gaussiánmi alebo nad grafom.

Vyberám **GaussianEditor** [1]. Edituje 3DGS scény priamo, pokrýva operácie color, style aj prácu s objektom a je z dostupných nástrojov najzrelší. Z kandidátov som zvažoval Instruct-NeRF2NeRF [3] (je pre NeRF, nie pre GS, takže len ako inšpirácia pre editáciu cez SDS) a SceneTeller / GALA3D (layout-guided generovanie, ktoré je skôr text-to-scene než úprava existujúcej scény). Táto fáza je najmenej ustálená, viac k nej v kapitole 4.

Príklad úpravy scény promptom ukazuje obrázok 3.4.



Obr. 3.4: Príklad úpravy 3D scény riadenej textom pomocou GaussianEditor. Prevzaté z [1].

3.6 Fáza 06: Gaussian Splatting a render

Vstup: riedky pointcloud zo SfM (inicializácia) a tréningové obrázky s pózami. **Výstup:** milióny 3D gaussiánov $(\mu, \Sigma, \alpha, \mathrm{SH})$ — real-time render (100+ FPS).

Gaussiány sa naštartujú z bodov SfM (poloha a malá izotropná kovariancia), scéna sa zobrazí z tréningových pohľadov, spočíta sa loss voči referenčným obrázkom a podľa neho sa gaussiány adaptívne pridávajú, odoberajú a dolaďujú.

Vyberám **3DGS** v oficiálnej implementácii od INRIA [4] — pôvodná implementácia zo SIGGRAPH 2023, referenčný benchmark optimalizovaný na CUDA, nad ktorým je postavený aj editor z fázy 05. Z kandidátov som zvažoval gsplat z nerfstudio (modulárna Python implementácia, lepšia na experimenty) a LangSplat / Feature 3DGS (gaussiány s CLIP kanálmi — alternatíva, ak by sme chceli mať sémantiku priamo v gaussiánoch).

Príklad scény reprezentovanej Gaussian Splattingom ukazuje obrázok 3.5.



Obr. 3.5: Reálna scéna zrekonštruovaná a zobrazená metódou 3D Gaussian Splatting (scéna Truck z datasetu Tanks and Temples). Zdroj: projektová stránka 3D Gaussian Splatting [4], `https://repo-sam.inria.fr/fungraph/3d-gaussian-splatting/` [cit. 7. 6. 2026].

Kapitola 4

Zhrnutie a plán

4.1 Odporúčaný stack

Z rozboru v kapitole 3 mi vyšiel odporúčaný stack metód, ktorý zhŕňa tabuľka 4.1. Pri každej fáze uvádzam hlavnú voľbu a kandidátov, ktorí prichádzali do úvahy.

Fáza	**Hlavná voľba**	**Kandidáti / alternatívy**
01	COLMAP	MASt3R / VGGSfM (učené)
02	Grounded-SAM 2	ODISE / OpenSeeD, YOLO-World + SAM
03	ConceptGraphs	OpenMask3D, OV-SAM3D
04	ConceptGraphs	HOV-SG
05	GaussianEditor	Instruct-NeRF2NeRF, SceneTeller / GALA3D
06	3DGS (INRIA)	gsplat, LangSplat / Feature 3DGS

Tabuľka 4.1: Odporúčaný stack metód pre jednotlivé fázy reťazca. Fázy 03 a 04 pokrýva jeden systém (ConceptGraphs).

4.2 Pripravenosť a poradie skladania

Nie všetky fázy sú rovnako náročné na realizáciu. Rozdelil som ich do troch skupín podľa zrelosti, čo zároveň určuje aj poradie, v akom by som ich skladal.

Out-of-the-box (stačí použiť). Sem patria SfM (fáza 01, COLMAP), 2D segmentácia (fáza 02, Grounded-SAM + CLIP) a zobrazovanie (fáza 06, 3DGS). Pre

všetky existujú open-source, dobre zdokumentované a produkčne stabilné implementácie, takže ich stačí použiť.

Integrácia (modifikovať / dotrénovať). Sem patrí prenos do 3D (fáza 03) a graf scény (fáza 04), oba pokryté systémom ConceptGraphs. Referenčné implementácie existujú, len ich treba trochu vyladiť — pri čisto RGB vstupe doplniť odhad hĺbky z jednej snímky (mono-depth) a doladiť odvodzovanie relácií cez LLM.

Bottleneck (najnáročnejšie). Najťažšia je fáza 05 (úprava promptom). Treba v nej navrhnúť routing operácií podľa typu promptu a vyriešiť 3D inpainting, teda dorobenie scény po odstránení alebo posune objektu, čo je stále otvorený problém. Hlavná výskumná kontribúcia bude pravdepodobne práve tu — kým ostatné fázy sú väčšinou o poskladaní hotových nástrojov, fáza 05 ponúka priestor na vlastný prínos.

4.3 Zhodnotenie

Reťazec vedome stavia na existujúcich metódach a jeho hodnota je v tom, ako sú poskladané do funkčného celku. Pre každú fázu som vybral najzrelší a prakticky najlepšie použiteľný nástroj, takže väčšina reťazca sa dá reálne poskladať z hotových open-source modulov. Vďaka modularite sa dá navyše ktorákoľvek voľba neskôr nahradiť novším kandidátom bez zásahu do zvyšku.

Hlavné obmedzenie je, že návrh je zatiaľ len na papieri — je premyslený a zdôvodnený, ale ešte neimplementovaný a neoverený. Otvorené ostávajú hlavne otázky okolo fázy 05 a ďalej to, ako kvalitne prejde význam do 3D pri čisto RGB vstupe bez hĺbkového senzora. Týmto smerom by mala ísť ďalšia práca.

Záver

V tejto práci som navrhol reťazec, ktorý z obyčajných fotiek alebo videa reálnej scény spraví jej upraviteľnú 3D verziu, ktorá sa dá meniť textovými a obrázkovými promptmi. Reťazec som rozdelil do šiestich na seba nadväzujúcich fáz — SfM, 2D segmentácia, prenos do 3D, graf scény, úprava promptom a render cez Gaussian Splatting — a pri každej som popísal jej vstup, výstup a postup.

Hlavný výsledok je výber a zdôvodnenie metódy pre každú fázu. Pri každej fáze som porovnal kandidátov a vybral ten najzrelší a prakticky najlepšie použiteľný, čím mi vyšiel konkrétny stack: COLMAP (01), Grounded-SAM 2 (02), ConceptGraphs (03 aj 04), GaussianEditor (05) a 3DGS (06). Tento stack je zhrnutý v tabuľke 4.1 a dá sa z veľkej časti poskladať z hotových open-source nástrojov.

Fázy som zároveň zhodnotil podľa pripravenosti. Väčšinu (01, 02, 06) stačí použiť tak ako sú, fázy 03 a 04 (ConceptGraphs) treba trochu doladiť na RGB vstup a najnáročnejšia je fáza 05 (úprava promptom) — routing operácií a 3D inpainting sú stále otvorený problém, a práve tu vidím najväčší priestor na vlastný prínos.

Návrh je zatiaľ teoretický — je zdôvodnený, ale ešte neimplementovaný. Prirodzené pokračovanie je teda postupne reťazec poskladať v poradí podľa pripravenosti, overiť ho na reálnych scénach a potom sa sústrediť na fázu úpravy. Modulárny návrh pritom dáva stabilný rámec, do ktorého sa dajú jednotlivé metódy postupne dopĺňať a vymieňať za novšie.

Literatúra

[1] Yiwen Chen, Zilong Chen, Chi Zhang, Feng Wang, Xiaofeng Yang, Yikai Wang, Zhongang Cai, Lei Yang, Huaping Liu, and Guosheng Lin. GaussianEditor: Swift and controllable 3D editing with gaussian splatting. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 21476–21485, 2024.

[2] Qiao Gu, Alihusein Kuwajerwala, Sacha Morin, Krishna Murthy Jatavallabhula, Bipasha Sen, Aditya Agarwal, Corban Rivera, William Paul, Kirsty Ellis, Rama Chellappa, Chuang Gan, Celso Miguel de Melo, Joshua B. Tenenbaum, Antonio Torralba, Florian Shkurti, and Liam Paull. ConceptGraphs: Open-vocabulary 3D scene graphs for perception and planning. In *Proceedings of the IEEE International Conference on Robotics and Automation (ICRA)*, pages 5021–5028. IEEE, 2024.

[3] Ayaan Haque, Matthew Tancik, Alexei A. Efros, Aleksander Holynski, and Angjoo Kanazawa. Instruct-NeRF2NeRF: Editing 3D scenes with instructions. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, 2023.

[4] Bernhard Kerbl, Georgios Kopanas, Thomas Leimkühler, and George Drettakis. 3D gaussian splatting for real-time radiance field rendering. *ACM Transactions on Graphics*, 42(4), 2023.

[5] Shilong Liu, Zhaoyang Zeng, Tianhe Ren, Feng Li, Hao Zhang, Jie Yang, Qing Jiang, Chunyuan Li, Jianwei Yang, Hang Su, Jun Zhu, and Lei Zhang. Grounding DINO: Marrying DINO with grounded pre-training for open-set object detection. In *Computer Vision – ECCV 2024*. Springer, 2024.

[6] Nikhila Ravi, Valentin Gabeur, Yuan-Ting Hu, Ronghang Hu, Chaitanya Ryali, Tengyu Ma, Haitham Khedr, Roman Rädle, Chloe Rolland, Laura Gustafson, et al. SAM 2: Segment anything in images and videos. In *International Conference on Learning Representations (ICLR)*, 2025. arXiv:2408.00714.

[7] Tianhe Ren, Shilong Liu, Ailing Zeng, Jing Lin, Kunchang Li, He Cao, Jiayu Chen, Xinyu Huang, Yukang Chen, Feng Yan, et al. Grounded SAM: Assembling open-world models for diverse visual tasks. arXiv:2401.14159, 2024. Technická správa.

[8] Johannes L. Schönberger and Jan-Michael Frahm. Structure-from-motion revisited. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 4104–4113, 2016.

[9] Abdelrhman Werby, Chenguang Huang, Martin Büchner, Abhinav Valada, and Wolfram Burgard. Hierarchical open-vocabulary 3D scene graphs for language-grounded robot navigation. In *Robotics: Science and Systems (RSS)*, 2024.